TCP: Control de Congestión

2017

Servicios de TCP

- Control de Errores:
  - Mecanismo protocolar que permite ordenar los segmentos que llegan fuera de orden y recuperarse mediante solicitudes y/o retransmisiones de aquellos segmentos perdidos o con errores.
  - Se realiza por cada conexión: End-to-End, App-to-App.
- Control de Flujo (Flow-Control):
  - Mecanismo protocolar que permite al receptor controlar la tasa a la que le envía datos el transmisor.
  - Controla cuanto puede enviar una aplicación sabiendo que la receptora tiene capacidad de recibirlo (espacio en RxBuf).

Servicios de TCP (Cont.)

- Control de Flujo (Cont.):
  - Se realiza por cada conexión: End-to-End, App-to-App.
  - Permite que aplicaciones con diferentes capacidades dialoguen regulando la velocidad, tasa de transmisión.
  - Tiene en cuenta solo el estado del receptor, no el de la red.
- Control de Congestión:
  - Se realiza por cada conexión: End-to-End, App-to-App.
  - Permite que aplicaciones no saturen la capacidad de la red.
  - Tiene en cuenta el estado de la red a diferencia del control de flujo que solo ve el receptor.

Control de Congestión TCP

- **Objetivo:** Controlar el tráfico que se envía evitando que se colapse la red y se descarte teniendo que retransmitirse.
- Se puede implementar End-to-End (caso TCP, RFC-5681 (ant. RFC-2581)).
- O tomando partida la red. Modelo basado en la Red: IP+TCP:RFC-3168 (similar a mecanismos L2/L3: Frame-Relay, ATM).
- **Congestión:** Problemas de delay en los routers, problemas de overflow y descarte.

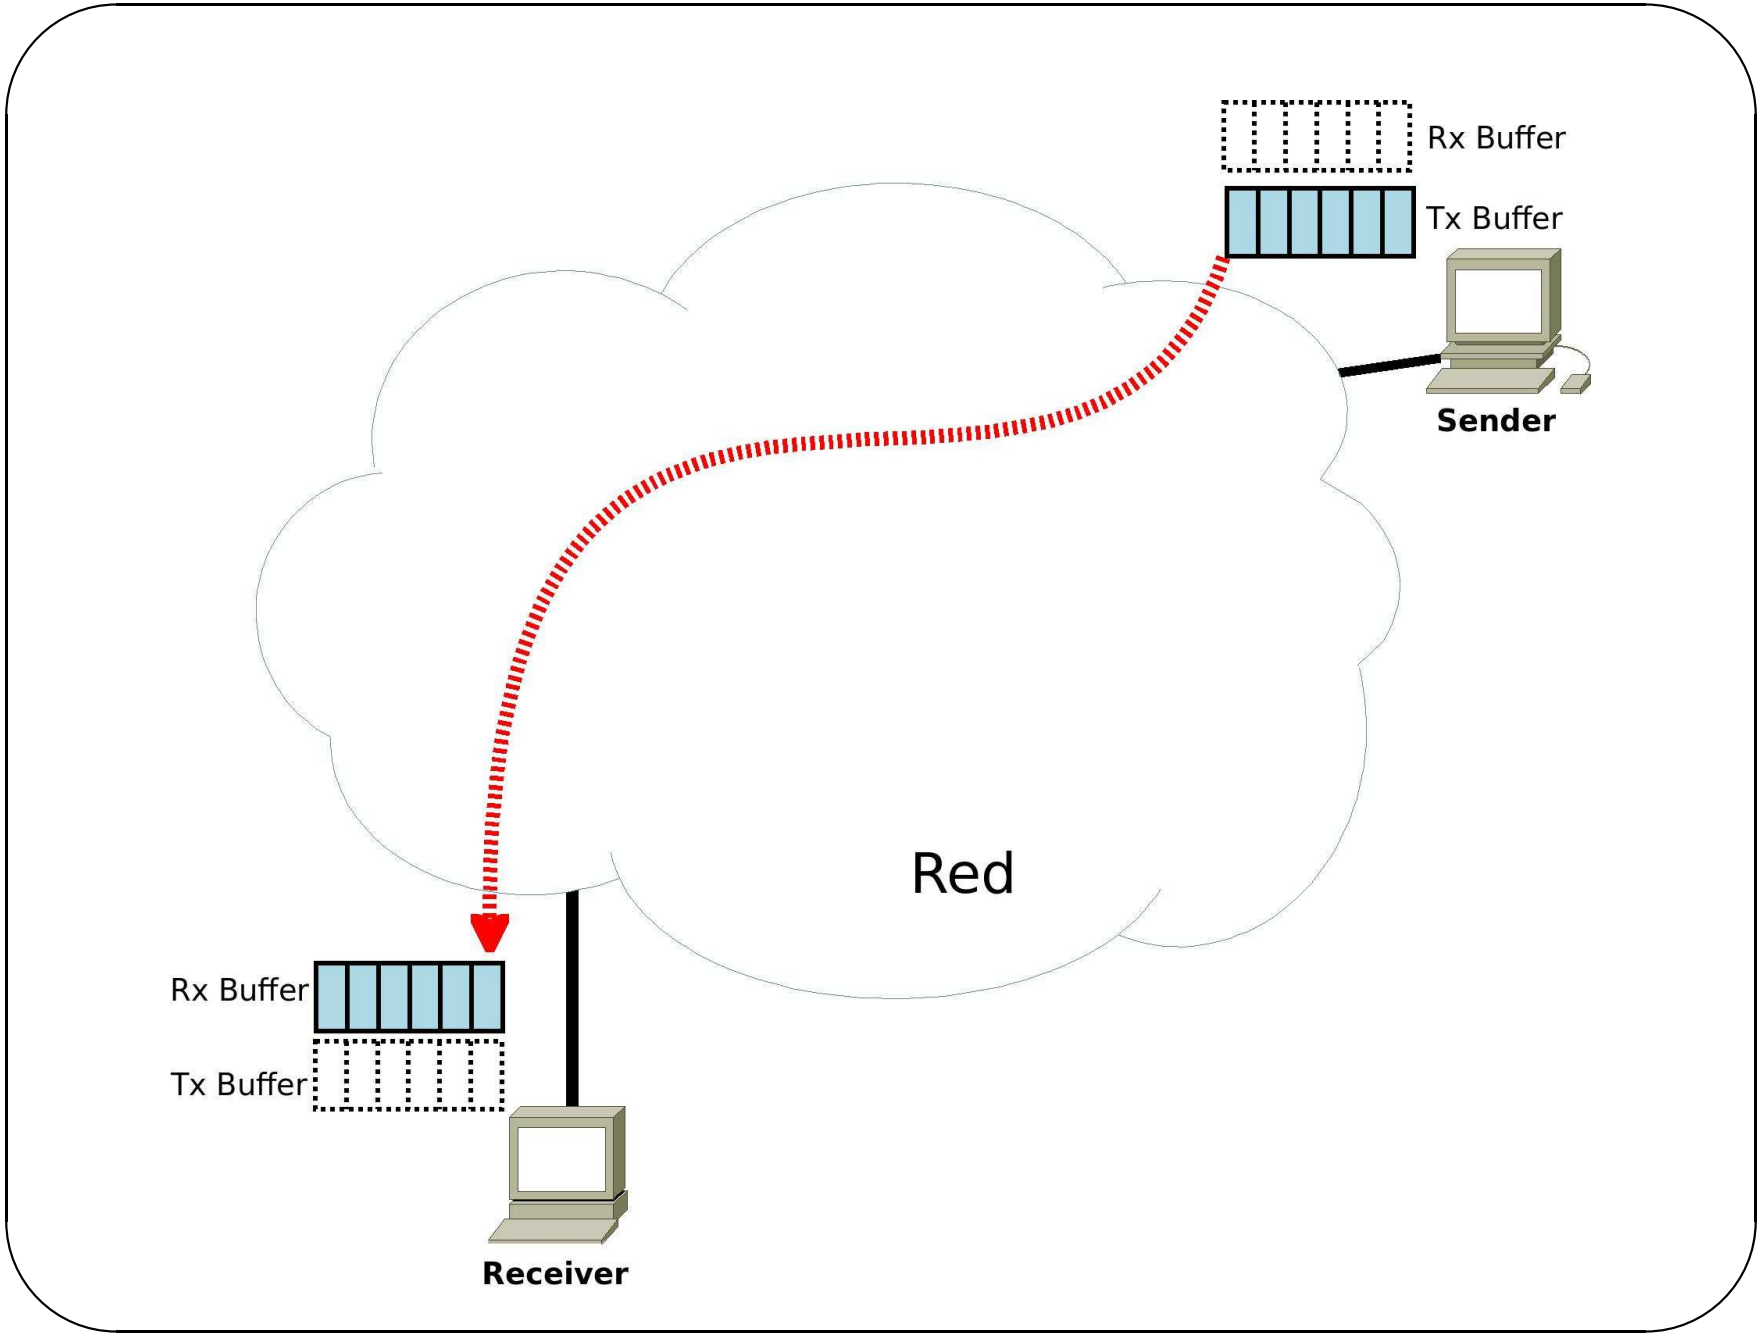
Rx Buffer
Tx Buffer
Sender
Red
Rx Buffer
Tx Buffer
Receiver

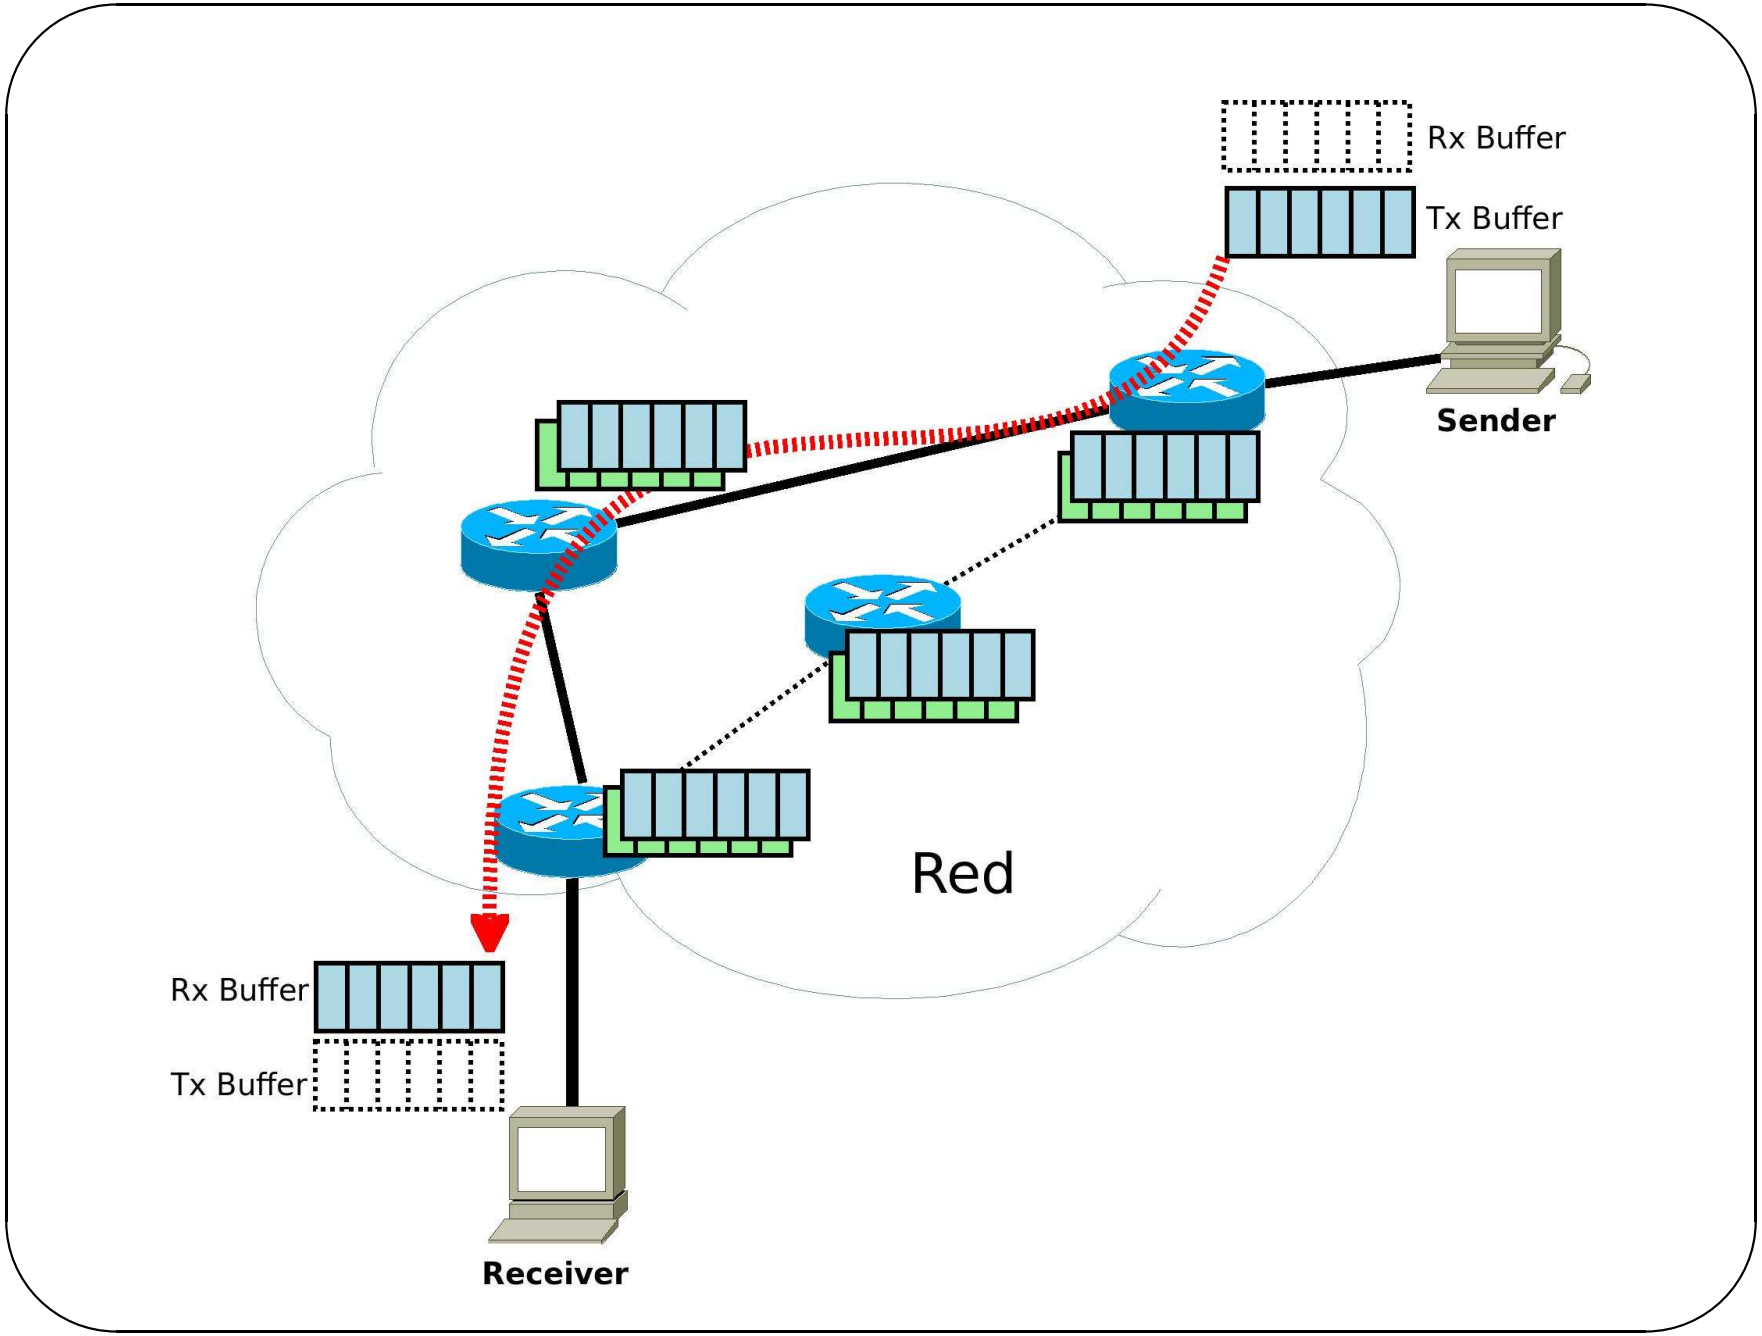
Rx Buffer
Tx Buffer
Sender
Red
Rx Buffer
Tx Buffer
Receiver

Causas de Congestión en la Red

- Límite de la capacidad de la red:
  - Velocidad de los Routers/Switches (CPU).
  - Capacidad de los Buffers de los Routers/Switches (Memoria).
  - Velocidad de los Enlaces (Interfaces).
- Utilización de la red:
  - Demasiado tráfico en la red (modelo de red compartida).
  - Se detecta por los nodos intermedios (router/switches) por ejemplo: cuando las colas sobrepasan un umbral. Se utiliza simple umbral o doble umbral (min,max).

Control de Congestión, Modelo End-to-End

- Modelo en el cual no participa la red (más implementado).
- Se utilizan nuevos parámetros a los de Control de Flujo (variables locales):
  - $cwnd$ Ventana de congestión. tiene en cuenta el estado de la red.
  - $ssthresh$ Slow Start Threshold (Umbral).
  - Se calcula: $MaxWin = Min(rwnd, cwnd)$. $rwnd$ era la ventana de recepción, usada para el control de flujo.

- $FlightSize = (LastByteSent - LastByteACKed)$ segmentos en vuelo, enviados y aún no confirmados ($Sent.No.ACKed$)
- Puede enviar: $Effective\_Win = MaxWin - FlightSize$.
- $MaxWin = Min(rwnd, cwnd)$ se calcula en base a quién esta más cargado, el receptor o la red.

- Diferentes Fases:
  - Si $cwnd < ssthresh$: Fase de crecimiento inicial: SS (Slow Start).
  - Si $cwnd >= ssthresh$ Fase de mantenimiento: CA (Congestion Avoidance).

Evolución Control de Congestión TCP (Old Version)

- 1974, 1era. Versión TCP, Vint Cerf, Bob Kahn, TCP inclíua también la capa de red (IP).
- Se divide en capas, TCP/IP, No considera control de Congestión inteligente.
  - "Ventana de congestión: $cwnd$" (no definida) crece hasta que se resetea, buffer overflow o error.
  - El destino podría limitarla con $rwnd$: válido para LAN.
  - No utiliza Slow Start (SS), se incrementa $cwnd++$ (en MSS) por cada RTT.
  - ACK perdido o segmento erróneo deriva en $cwnd = 1$.
  - Congestión/Límite de la red detectada por solo un tipo de evento, expira RTO.
  - Algoritmo no válido para entorno WAN, Internet.

Control de Congestión TCP (Old Version)

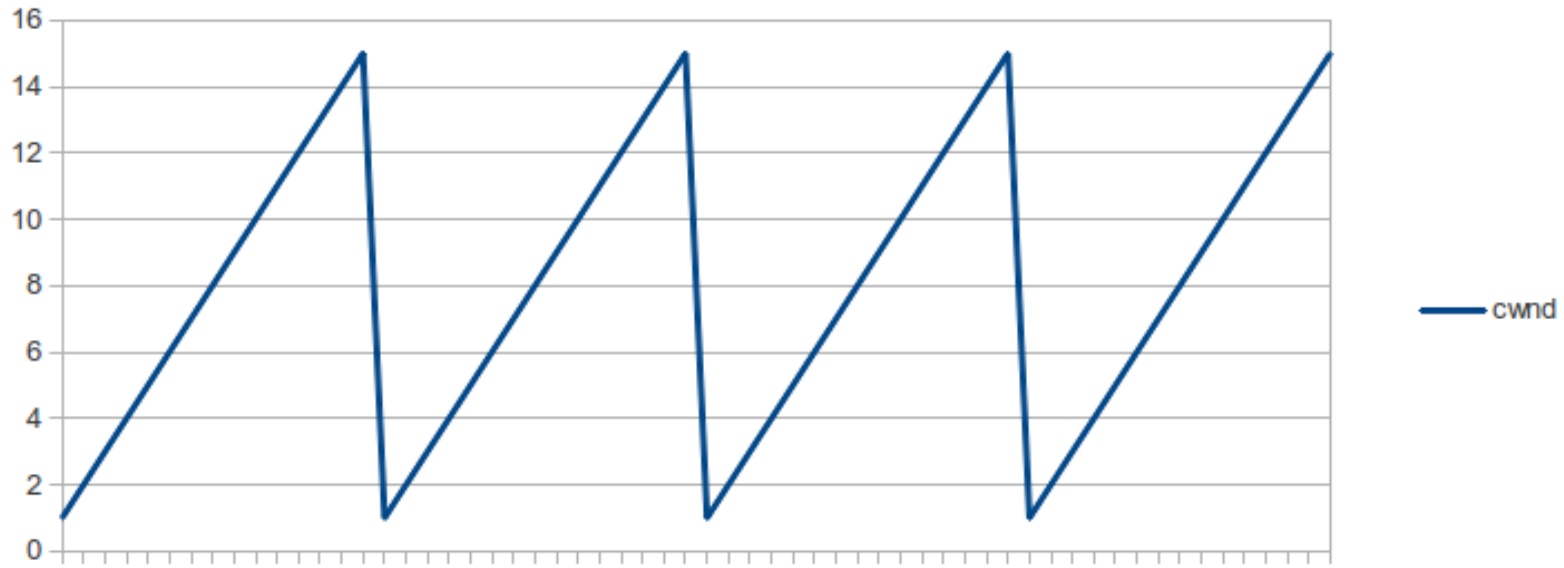

Control de Congestión TCP (Old Tahoe/Tahoe)

- Old Tahoe (BSD 4.2 - 1984 ?).
- TCP Tahoe (BSD 4.3 - 1988). Van Jacobson.
  - Utiliza Slow Start (SS), ventana crece exponencialmente, inicio $cwnd = IW = 1 * MSS$, o similar, IW (Init Window) puede ser 2 o 3 segmentos.
  - Una vez que se alcanza $sstresh$ se trabaja con Congestion Avoidance (CA).
  - Valor inicial $ssthresh = \infty$ (un valor alto).
  - Old-Tahoe sin Fast Retransmit, solo SS y CA.

- Tahoe agrega Fast Retransmit, aunque no esta bien implementado.
- Congestión detectada por RTO o 3DUP ACKs, derivaba en ambos casos en: Slow Start:
  $ssthresh = Min(cwnd/2, 2) * MSS$,
  $cwnd = LW = 1 * MSS$ (Loss Window). (mejor implementado en TCP Reno).
- Puede suceder que MSS sea diferente entre emisor y receptor, para este caso se considera $SMSS$ y $RMSS$. Los cálculos se hacen en base a $SMSS$.

Control de Congestión TCP (SS)

- Slow Start:
  - Crece exponencialmente, de forma rápida, no es slow (lento).
  - Se le llama Slow Start porque comienza a probar con pocos paquete, menos agresivo que el enfoque de enviar tanto como la la ventana de recepción permita.
  - Inicia $cwnd = IW = 1 * MSS$ (a veces se usa 2 o 3). Transmite y espera ACK.
  - ACK recibido, $cwnd++$: $cwnd = 2 * MSS$, nuevos ACKs: $cwnd = 4 * MSS$ ...
  - Si destino retarda ACK no se cumple.
  - Incrementa $cwnd++$ (en MSS) por cada ACK (varios por RTT, ráfaga).

Control de Congestión TCP (CA)

- Congestion Avoidance:
  - Ante el primer evento de congestión se calcula el $ssthresh$, primer ráfaga SS puro.
  - Una vez que $cwnd >= ssthresh$ crece de forma lineal.
  - Incrementa $cnwd++$ por cada RTT.
- Fast Retransmit: objetivo, recuperarse más rápido que un timeout. En Tahoe, FRT seguido por Slow Start. Vuelve al inicio $cwnd = 1 * MSS$.

Fases Control de Congestión TCP (SS y CA)

Assume that *ssthresh = 8*

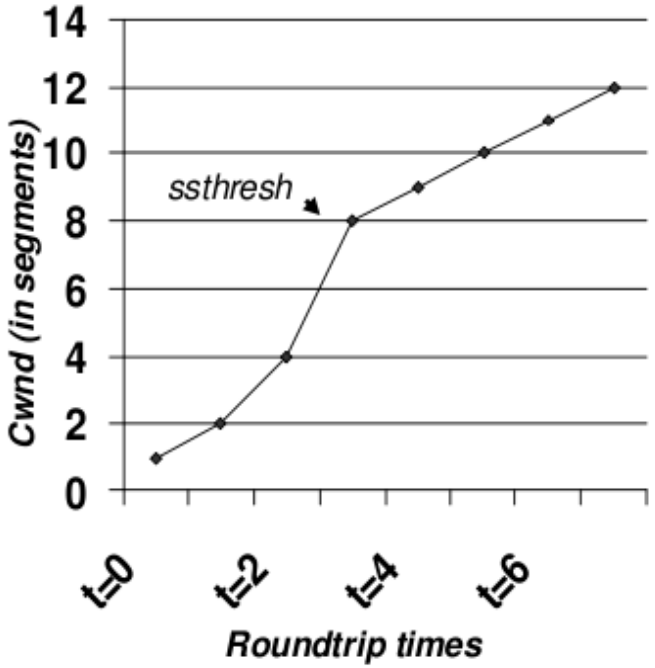

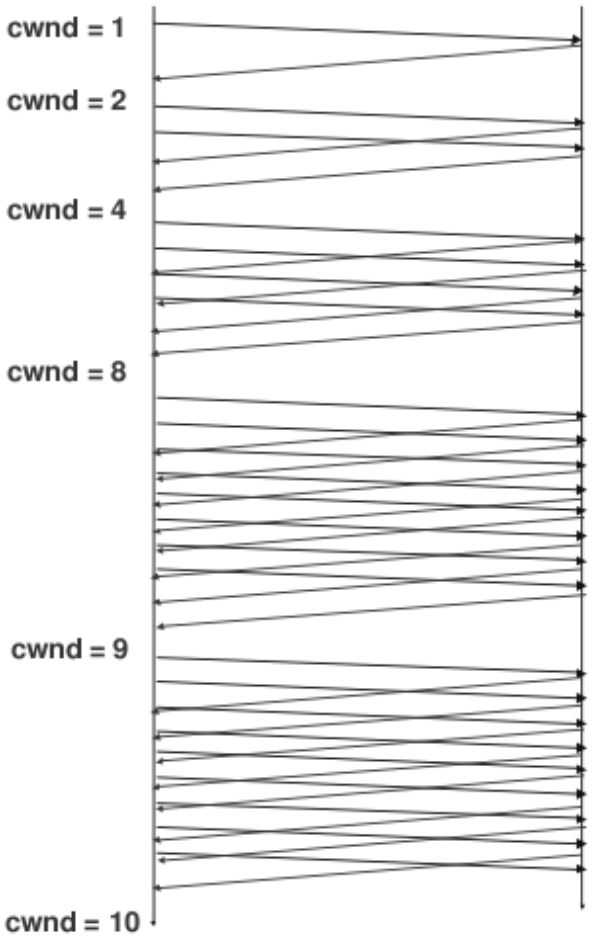

Control de Congestión TCP (Old Version vs. Tahoe)

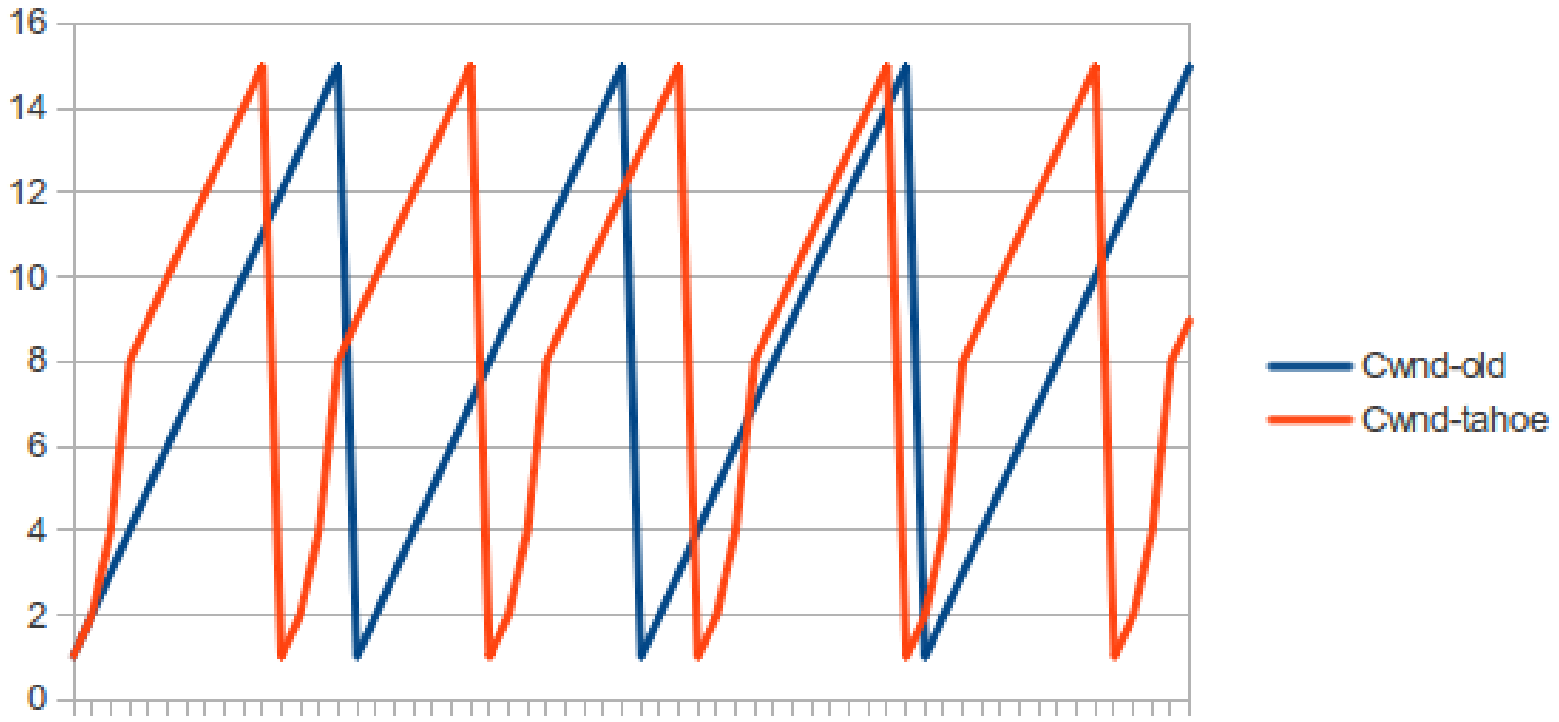

Control de Congestión TCP (Reno)

- TCP Reno (BSD 4.3 - 1990) Van Jacobson. RFC-2001/RFC-2581/RFC-5681.
- Se implementan de forma correcta Fast Retransmit y Fast Recovery.
  - Slow Start (SS)
  - Congestion Avoidance (CA).
  - Fast Retransmit (FRT)
  - Fast Recovery (FR).
- $FlightSize = cwnd$ si siempre tuvo datos para enviar, aunque en general $cwnd > FlightSize$, donde $cwnd$ crece sin enviar realmente datos, por lo tanto no reflejaría en ese caso el limite de la red.

Control de Congestión TCP (Reno FRT)

- Fast Retransmit:
  - Intenta recuperase más rápido que un timeout (expira RTO).
  - El receptor inmediatamente al recibir un segmento fuera de orden no debe esperar RTO del emisor sino generar un ACK (DUP ACK). No se debe retardar.
  - Debido que el emisor no sabe si se perdió o llego fuera de secuencia: espera por más ACK duplicados.
  - El emisor, si recibe 3 ACK duplicados (4 ACK para el mismo segmento) considera que se perdió (no es re-ordenamiento) y re-envía el segmento solicitado sin esperar RTO.

Control de Congestión TCP (Reno FR)

- Fast Recovery:
  - Si recibe 3 ACK duplicados (4 ACK para el mismo segmento) entro en Fast Retransmit y se reenvió el segmento.
  - Luego de Fast Retransmit entra en fase Fast Recovery, crece lineal.
  - Incrementa de forma lineal la ventana por cada ACK recibido, considera que es un espacio nuevo en la red (incremento inicialmente en 3, por los 3ACK duplicados)
  - Luego de Fast Recovery (se ACKed el segmento perdido) se realiza CA(Reno), no SS(Tahoe).

Control de Congestión TCP (Reno)

- Si se detectan 3DUP ACKs (Fast Retransmit):
  1. $ssthresh = Min(cwnd/2, 2) * MSS$, en RFC
     $ssthresh = Min(FlightSize/2, 2 * SMSS)$
  2. Fast Retransmit.
  3. Fast Recovery: $cwnd = (ssthresh + 3) * MSS$ (3 segments cached in receiver).
  4. Por cada ACK de segmento distinto que recibe incrementa la ventana $cwnd++$ (crece linealmente).
- Una vez recuperado (ACKed segmento perdido) vuelve “a la mitad”, $cnwd = ssthresh$, y comienza con CA.
- Los incrementos lineales realizados en FR previos a la recuperación se vuelven atrás (se achica un poco $cwnd$).

Control de Congestión TCP (Reno)

- Si se timeout, RTO expira.
  1. Retransmite el segmento perdido.
  2. $ssthresh = Min(cwnd/2, 2) * MSS$, en RFC $ssthresh = Min(FlightSize/2, 2 * SMSS)$
  3. $cwnd = LW = 1 * MSS$, en RFC $LW = 1 * SMSS$.
  4. Inicia con Slow Start como en los algoritmos anteriores.
  5. Comienza a retransmitir como Go-Back-N a partir del segmento que dio timeout de acuerdo a lo que le permite la ventana.

Control de Congestión TCP (Fases)

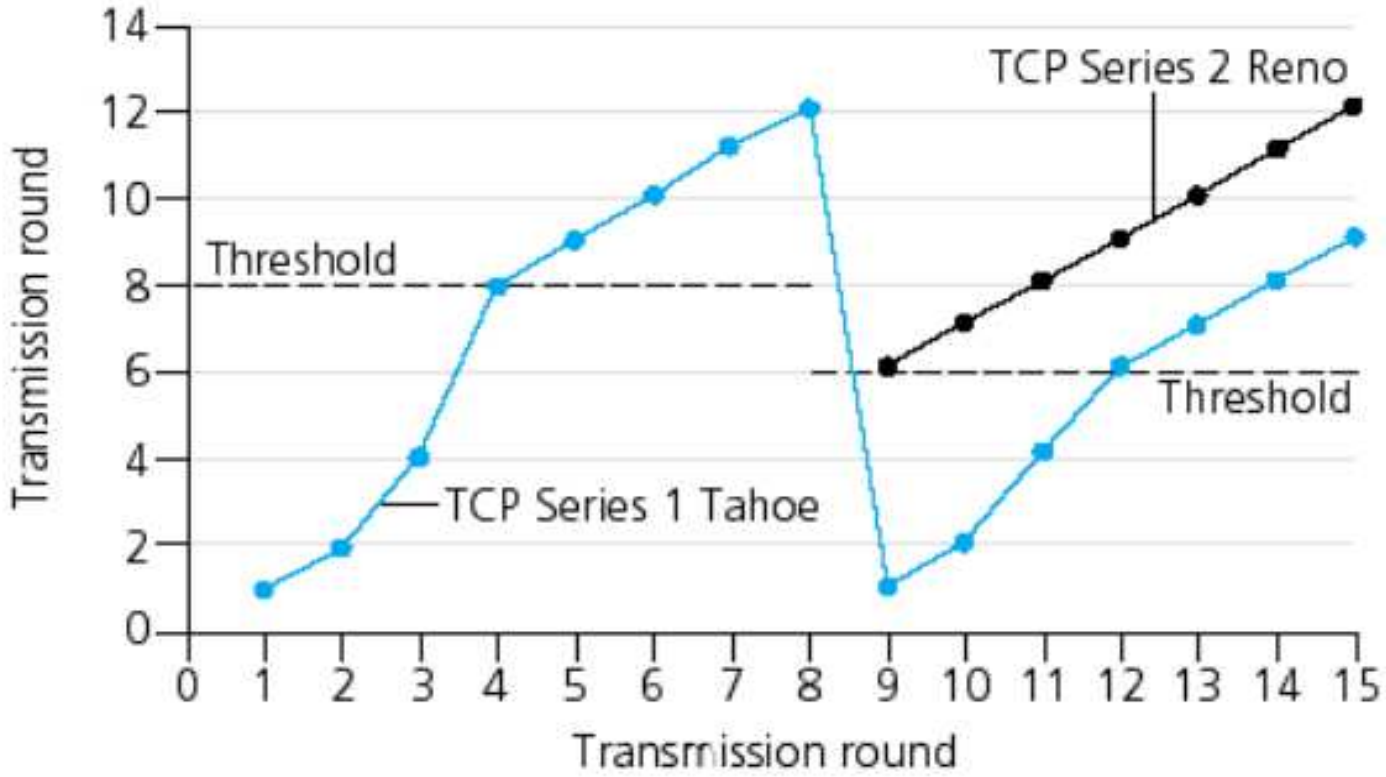

Ejemplo: Evolución Ventana de Congestión

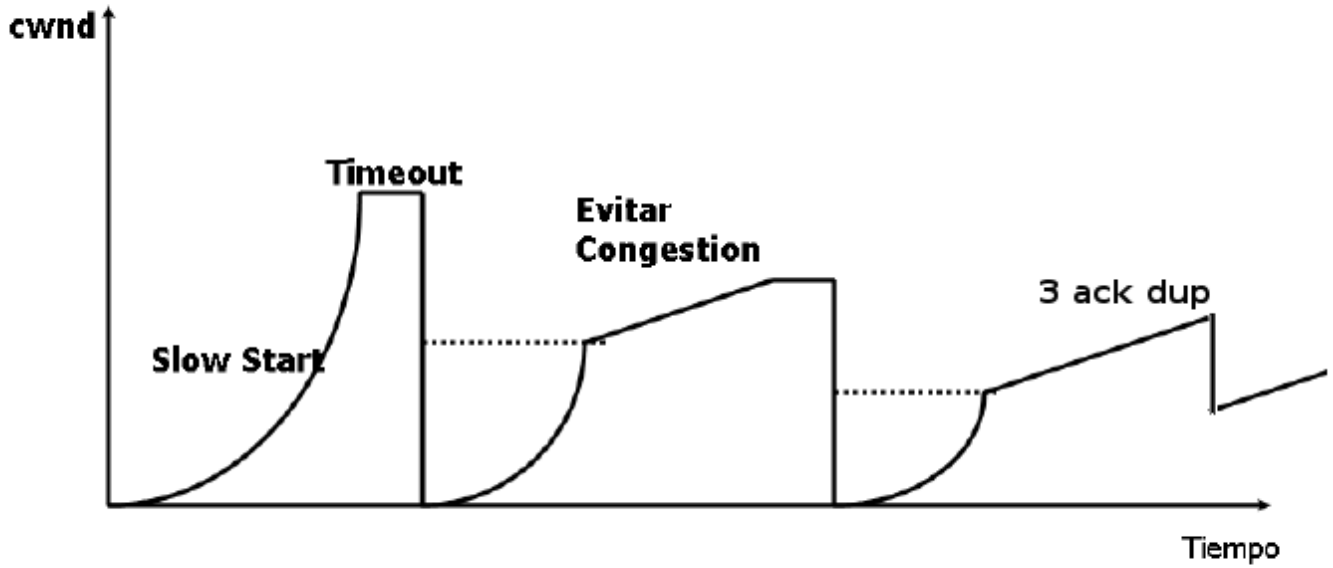

Control de Congestión TCP (Old vs. Tahoe vs. Reno)

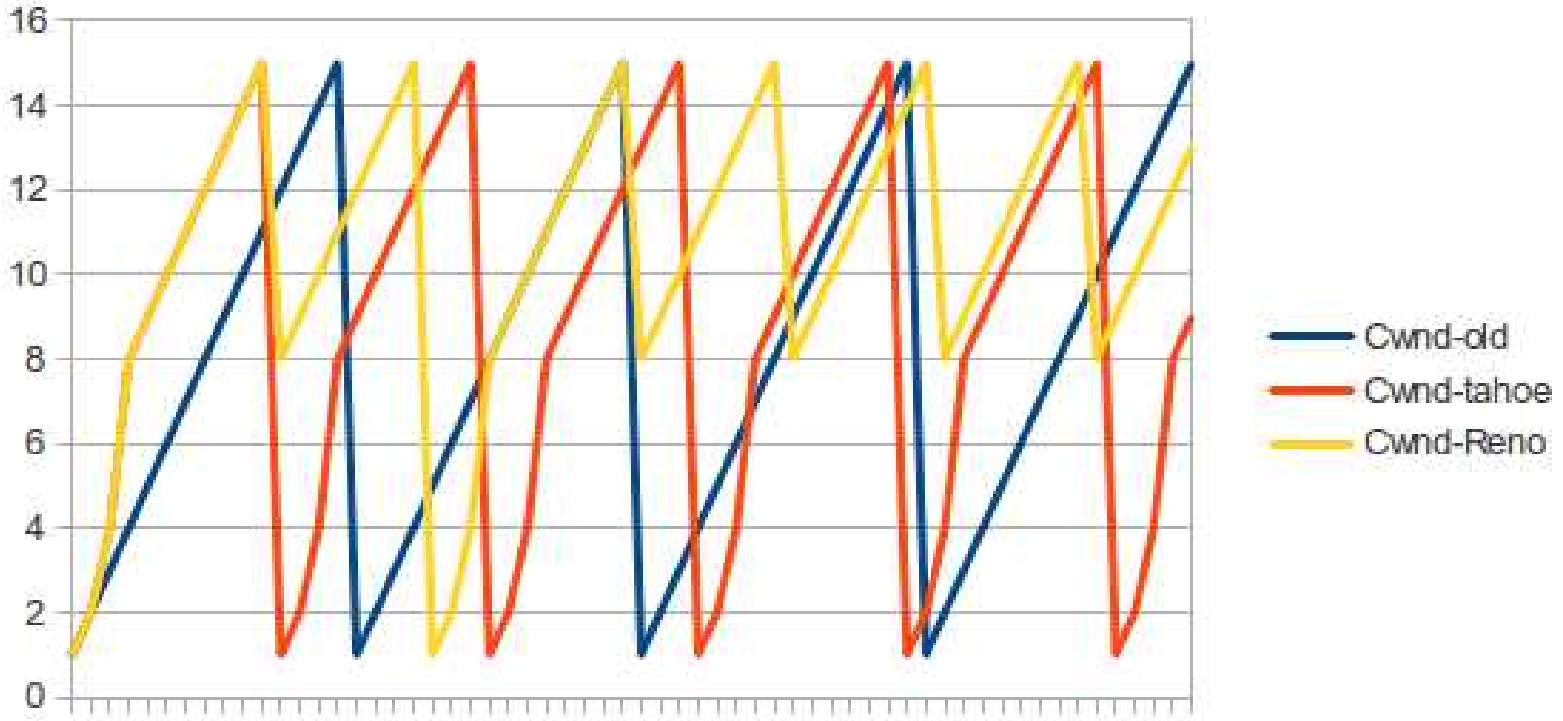

Control de Congestión TCP (Old vs. Tahoe vs. Reno) 3D

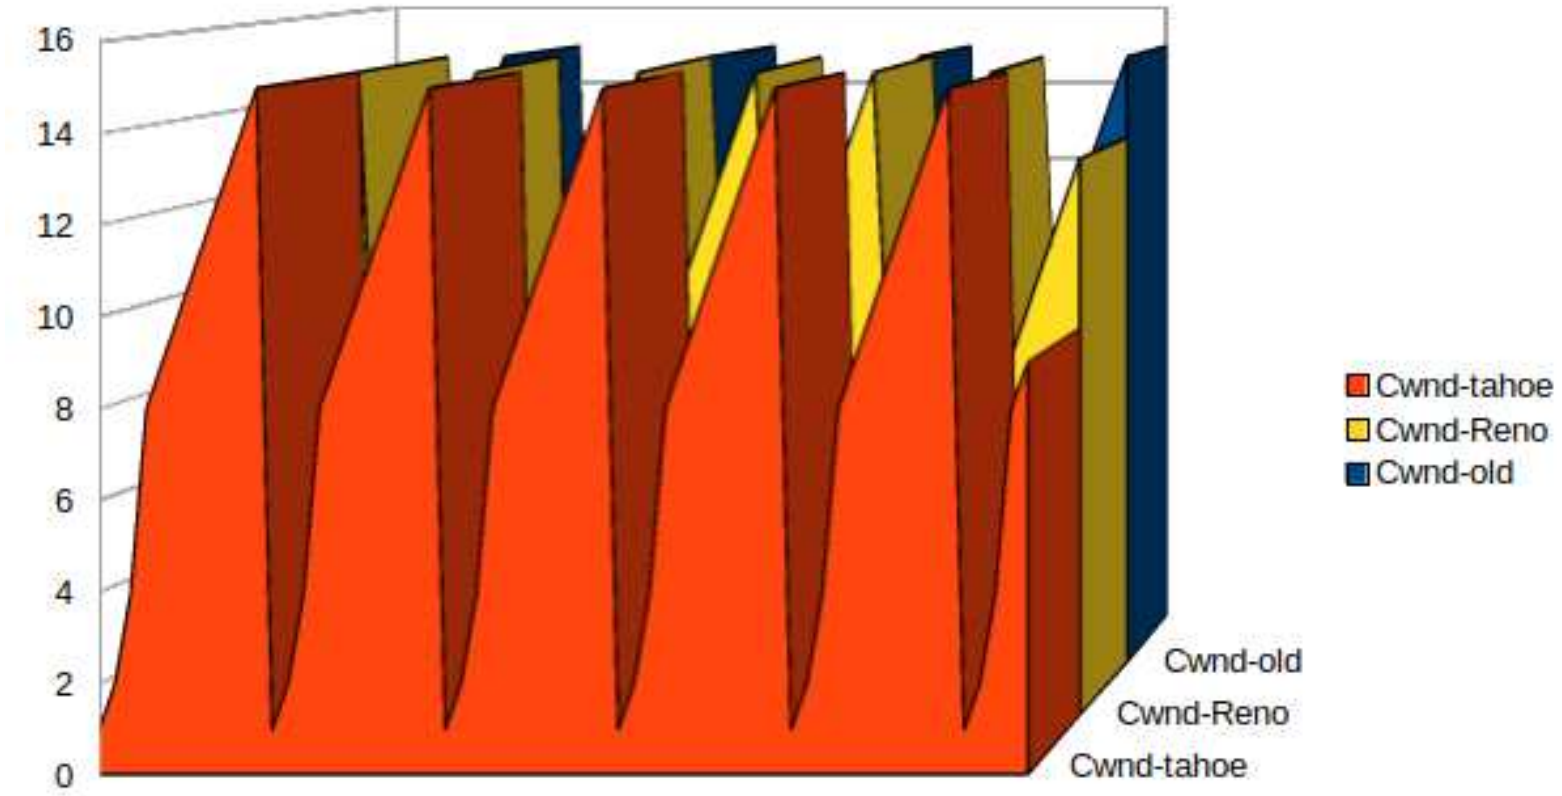

Control de Congestión TCP (Old vs. Tahoe vs. Reno)

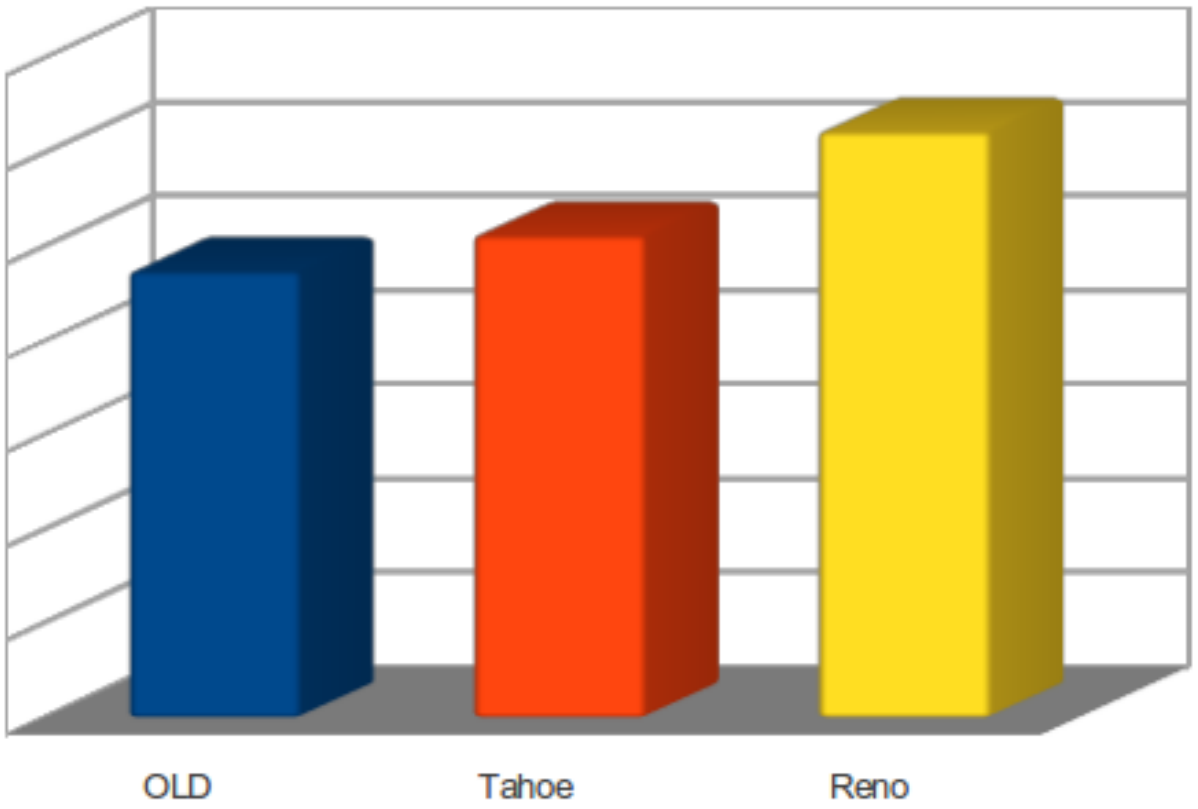

Modelo de Algoritmo TCP CC

```
void tcp_snd(event_t ev)
{
  switch (ev) {
    case (init):
     cnwd     = 1;
     ssthresh = INF;
     ...
     break;
    case (newack):
     if (cwnd<ssthresh) {
       /* Slow Start */
       /* 1 MSS for each ACK */
       cwnd++; // cwnd = cwnd + 1
     } else {
       /* Congestion Avoidance */
       /* 1 MSS for each RTT   */
       cwnd = cwnd + 1/cwnd;
     }
     ...
     break;
   ...
   ...
   case (timeout):
     ssthtesh = cwnd / 2;
     cwnd = 1;
     ...
     break;
     case (3ackdup):
     fast_retrans_fast_recover();
     ssthresh=cwnd / 2;
     cwnd = ssthresh + 3;
     ...
     }
}
```

AIMD (Additive Increase/Multiplicative Decrease)

- De acuerdo al modelo de TCP parece ser estable y justo.
- Utiliza un enfoque AIMD, crece de forma aditiva con ACK positivos y decrece de forma multiplicativa ante 3 ACK DUP (a la mitad).
- Se tratan de autoregular entre flujos.
- $a_i > 0; a_d = 0$
- $b_i = 1; 0 < b_d < 1$

$$w(t+1) = \begin{cases} a_i + b_i w(t) & si \quad (+) \\ a_d + b_d w(t) & si \quad (-) \end{cases}$$

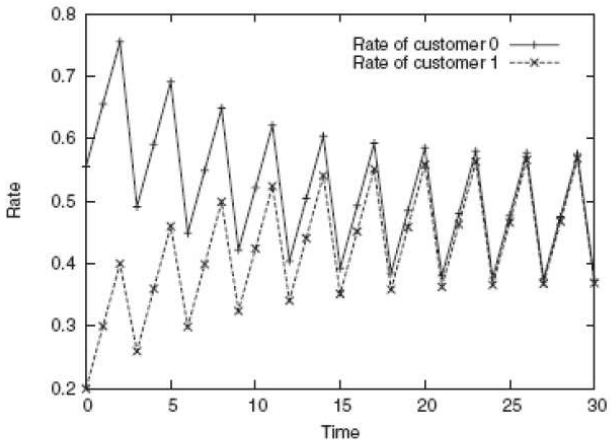

AIMD

AIMD (Additive Increase/Multiplicative Decrease)

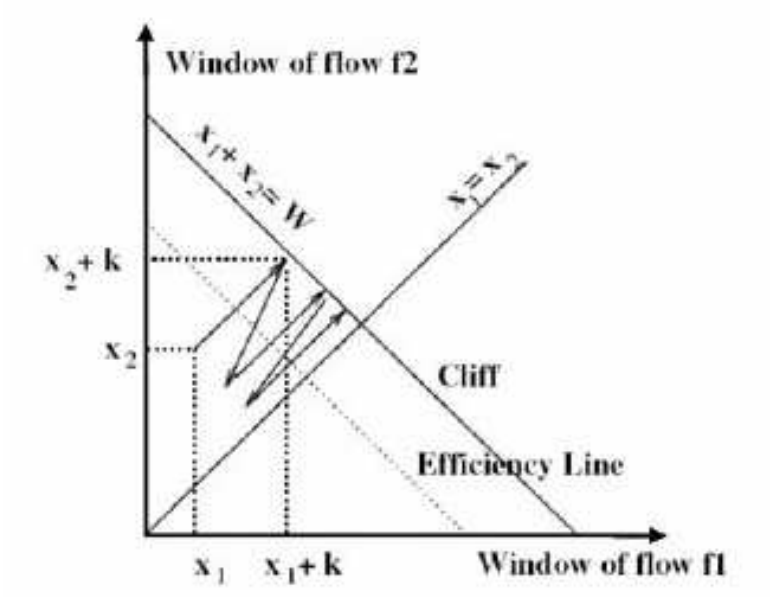

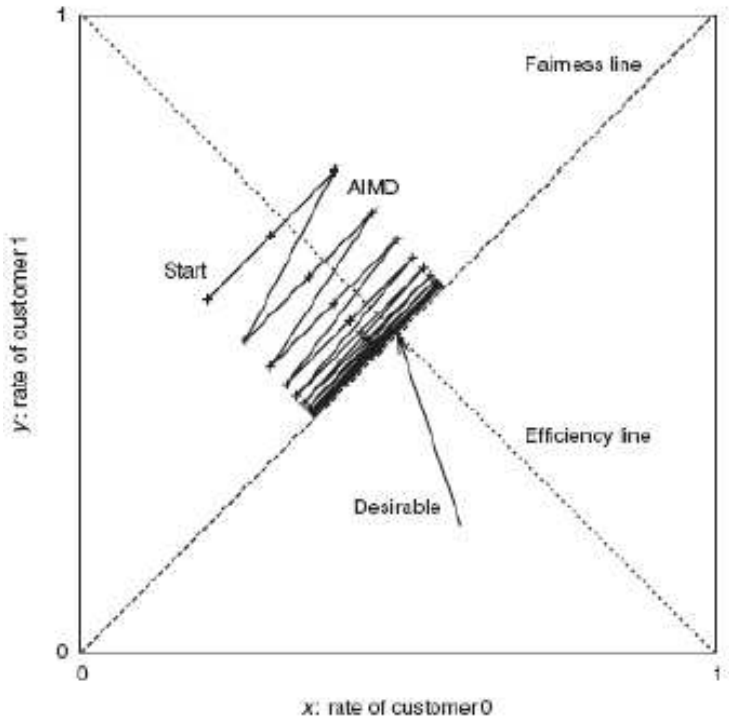

Control de Congestión TCP (New Reno)

- TCP Reno ante la pérdida de múltiples segmentos probalblemente termine en timeout (RTO expira) y vuelve a Slow Start.
- TCP New Reno, última versión RFC 6582(2012) hace obsoletas RFC 3782 (2004), RFC 2582(1999) S. Floyd, T. Henderson.
- Una vez que esta en Fast Recovery, por cada ACK duplicado permite enviar un nuevo segmento de manera de manterner la ventana “llena” para no terminar en un timeout para otro segmento.
- New Reno obtiene buen rendimiento con baja tasa de pérdida.

Otras Implementaciones TCP CC

- TCP New Reno (1996), mejora ante la pérdida de más segmentos.
- SACK (1996).
- TCP Vegas.
- TCP BIC.
- TCP Cubic.
- TCP Westwood.

Implementaciones Modelo

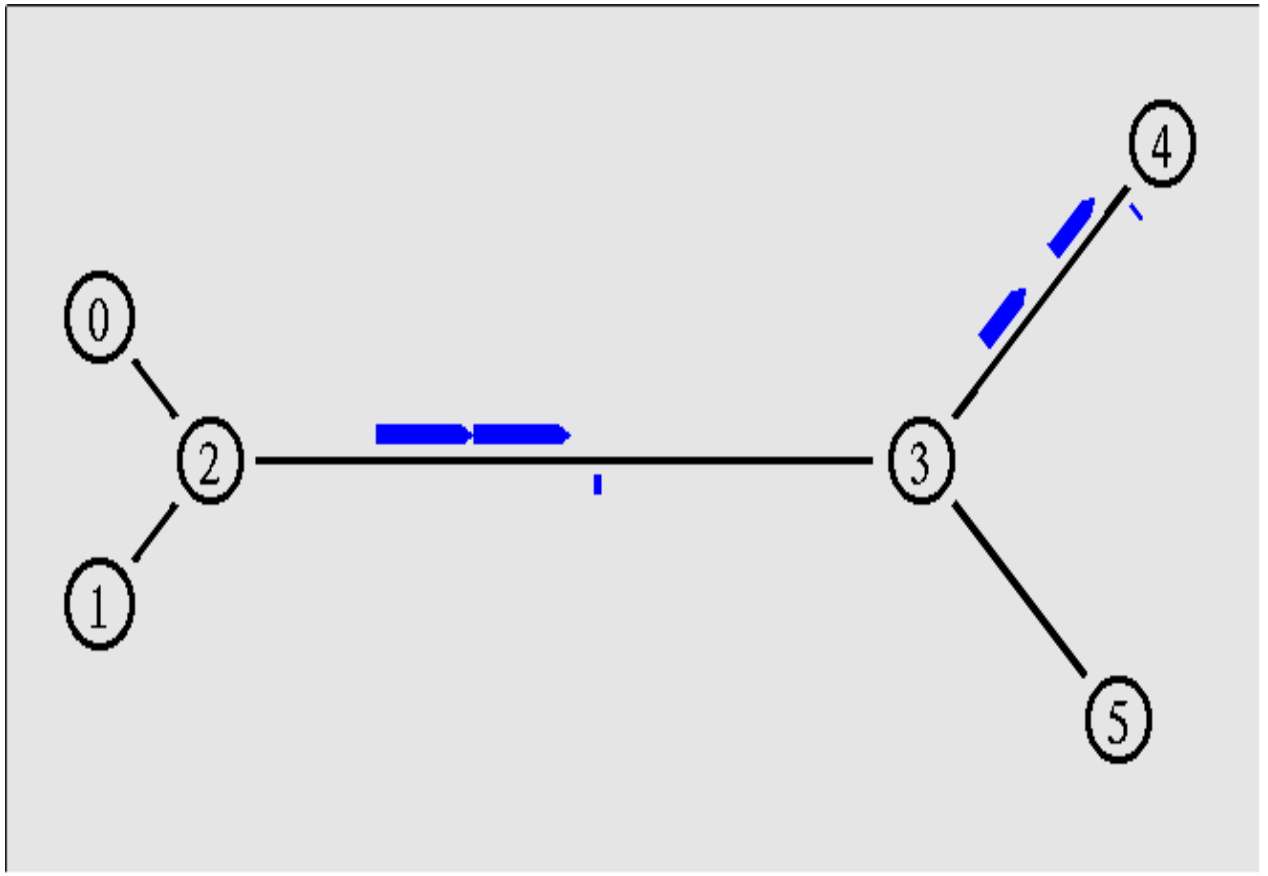

Implementaciones (Comparar Throughput)

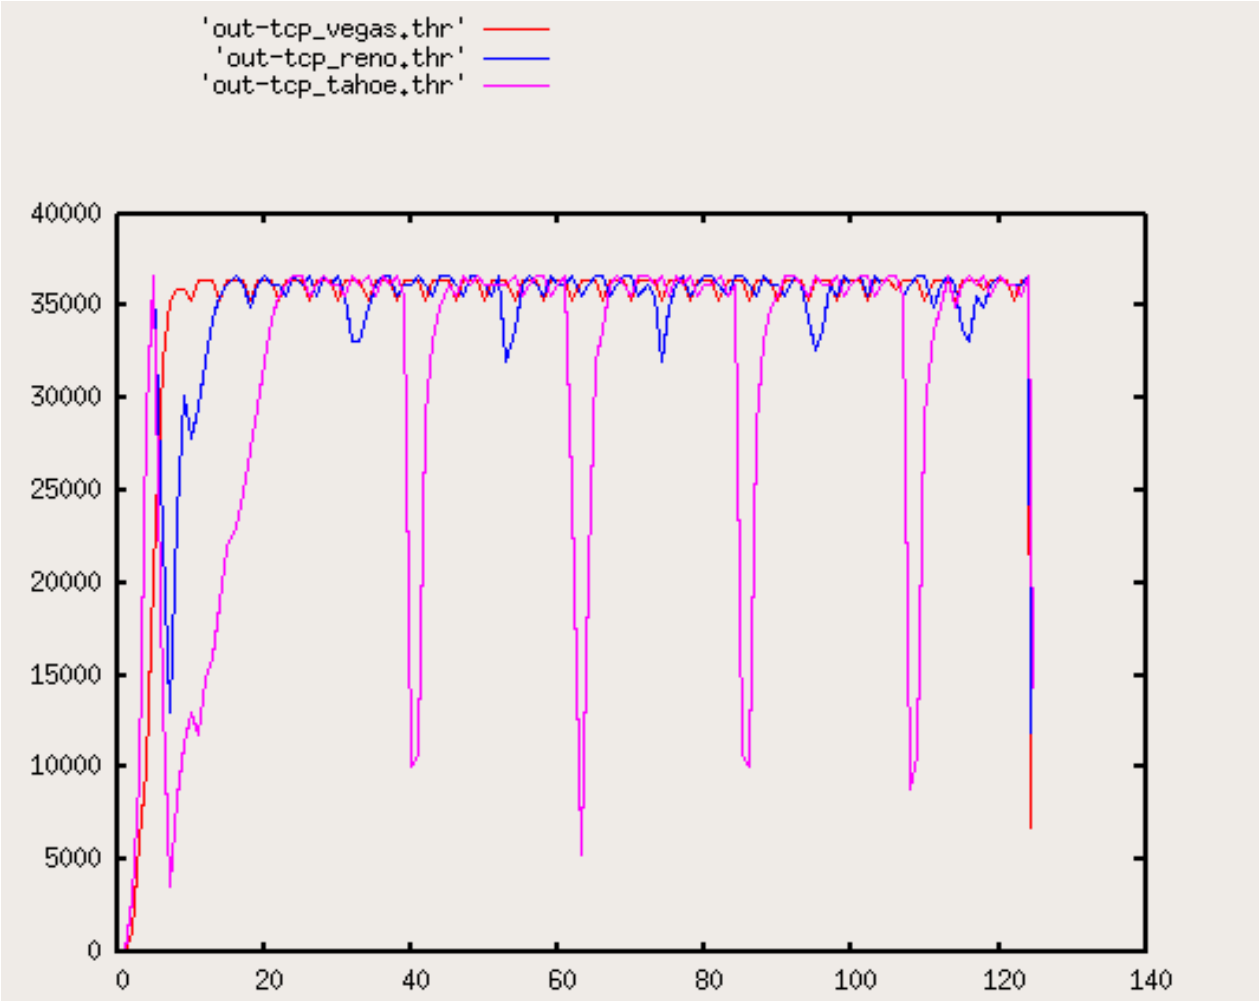

Implementaciones (Comparar cwnd)

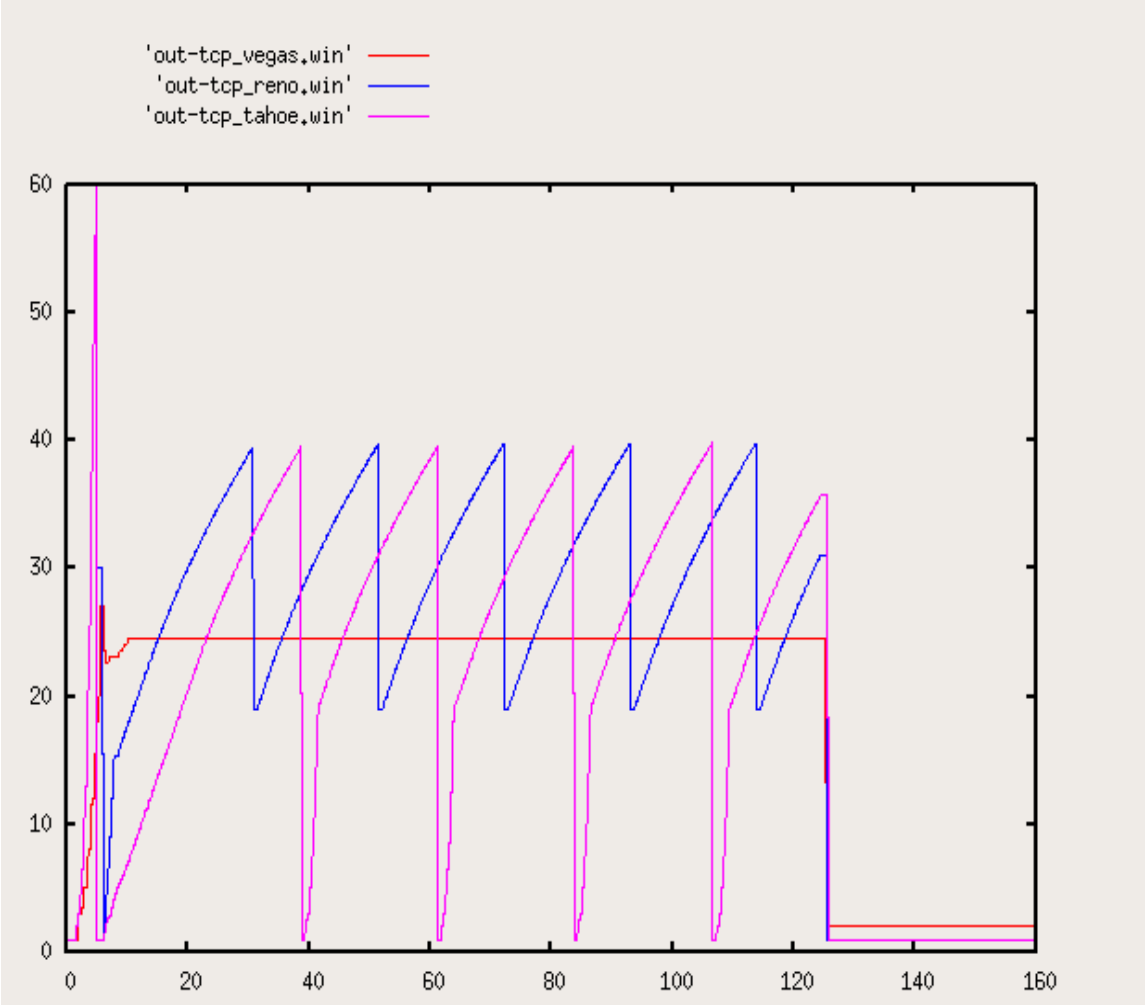

Control de Congestión por la Red

- TCP se monta sobre IP, best effort protocol, no considera en su origen QoS.
- Luego RFC-1349(ToS), obsoleta por RFC-2474(DSCP).
- Luego con RFC-3168 se agrega funcionalidad de CC por la red.
- Se utilizan campos reservados para marcar tráfico.

Control de Congestión por la Red (Cont'd)

- Los destinos congestionados, o routers intermedio pueden generar ICMP: Source Quench.
- Estos mensajes deberían ser considerados y bajar el data rate.
- No solo funcionan con UDP, es a nivel IP.
- Habitualmente son mensajes ignorados.
- TCP+IP con ECN es un mecanismo más adecuado.

Segmento TCP Marcado con ECE y CWR

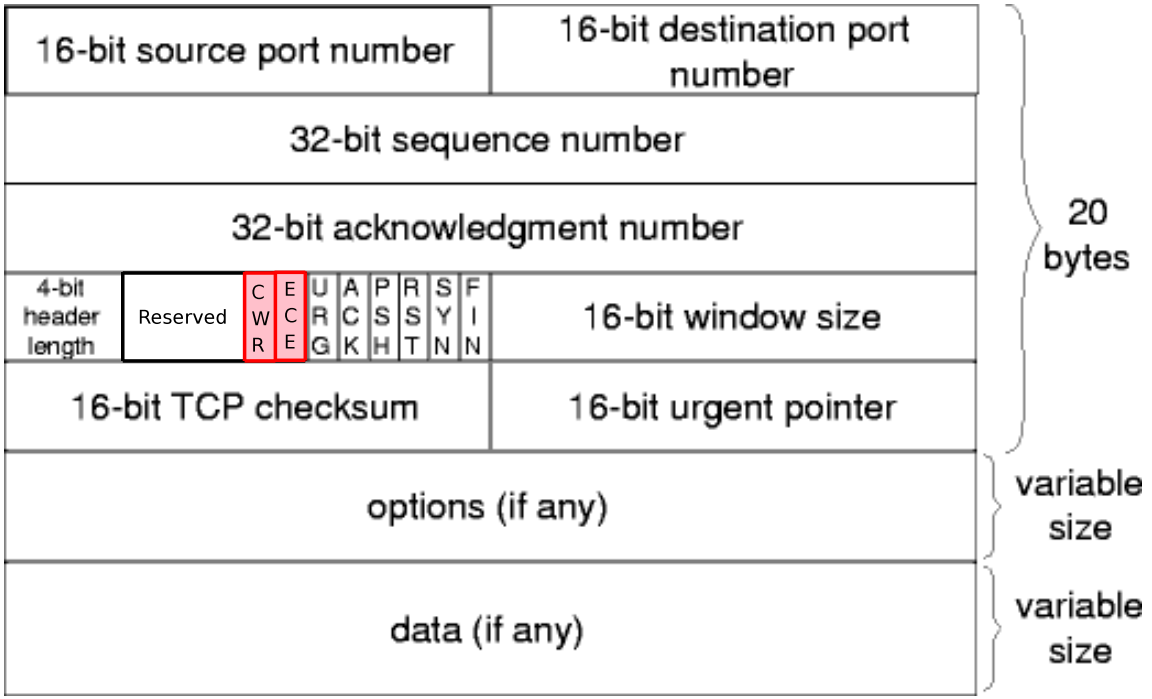

Datagrama IP Marcado con ECN: ECT, CE

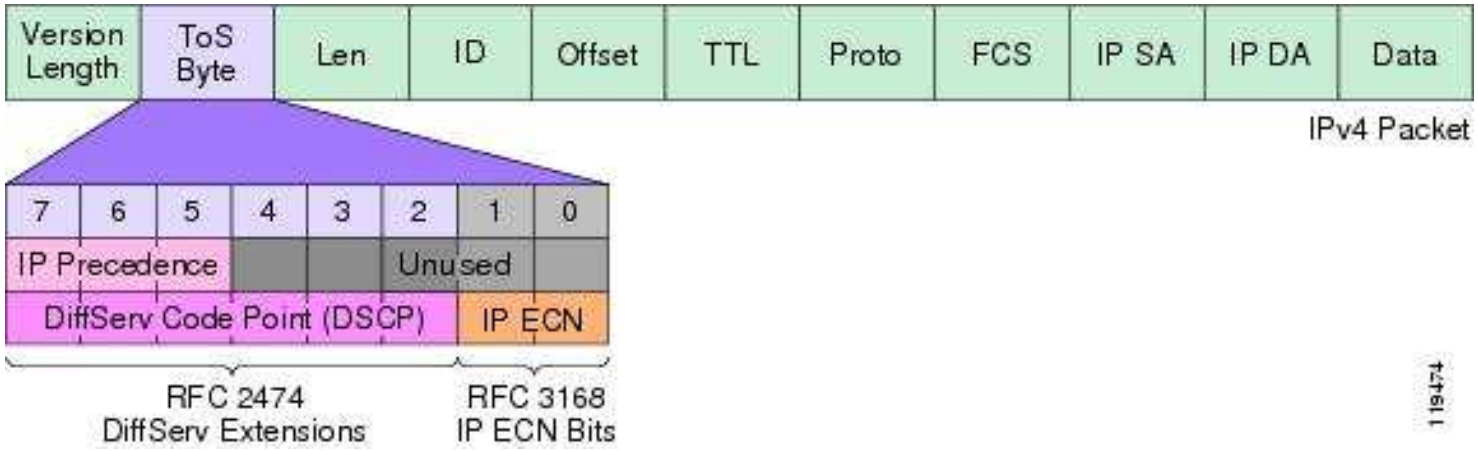

Control de Congestión TCP+IP (Cont'd)

- Al establecerse la conexión TCP, se negocia capacidad de ECN.
- Configuran en el Setup, SYN el $ECE = CWR = 1$ (ECN-Echo). "ECN-setup SYN packet".
- SYN+ACK configuran $ECE = 1$ y $CWR = 0$.
- Luego en datagramas IP se configuran $ECT(0) = 01$ o $ECT(1) = 10$ (ECN-Capable Transport).
- Si router (nodo intermedio) detecta congestión, tamaño de cola por encima de umbral aplica RED (Random Early Detection).
- Al aplicar RED, en lugar de descartar marca $CE = 11$ (Congestion Experienced).

TCP ECN Setup

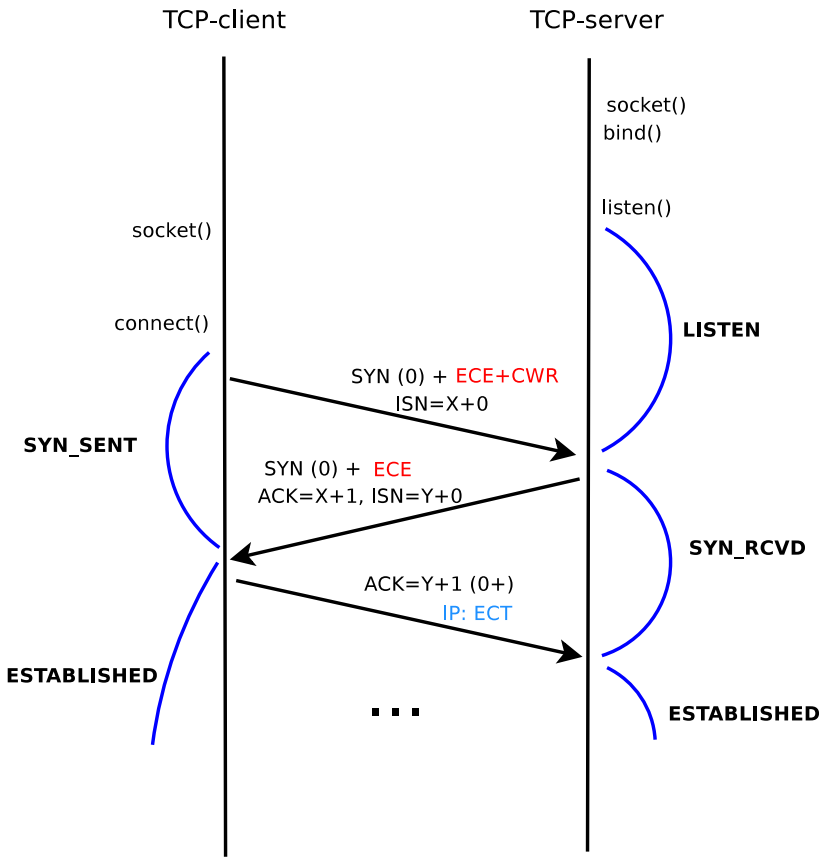

Control de Congestión TCP+IP (Cont'd)

- El receptor al recibir $CE = 11$, setea ECE en el próximo segmento de ACK.
- El emisor detecta $ACK == ECE == 1$ y aplica TCP CC clásico como si el mensaje hubiese sido descartado.
- El emisor también configura $CWR = 1$ (Congestion Window Reduced) para notificar que reacciono.

TCP+IP ECT+CE, ECE+CWR

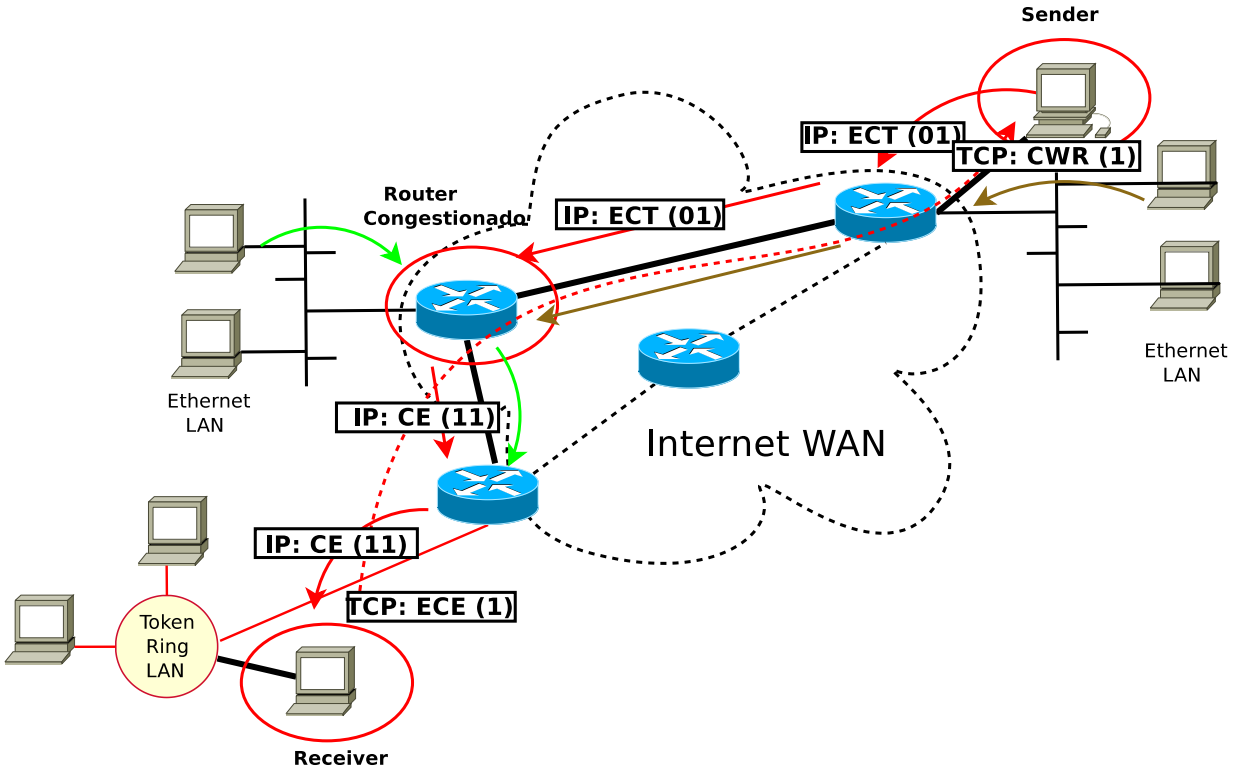

Fuentes de Información

- Kurose/Ross: Computer Networking (5th Edition).
- TCP/IP Illustrated, Volume 1: The Protocols, W. Richard Stevens.
- TCP/IP Illustrated, Volume 1: The Protocols, 2nd Ed. W. Richard Stevens, Kevin R. Fall.
- A Protocol for Packet Network Intercommunication. Cerf, Vinton G. & Kahn, Robert E. (1974).
- RFC 675, Specification of Internet Transmission Control Protocol, V. Cerf et al. (December 1974).
- RFCs: http://www.faqs.org/rfcs/ RFC-793, ... RFC-791, RFC-1323, RFC-2001, RFC-2018, RFC-2581, RFC-5681, RFC-2582, RFC-6582, RFC-3168, RFC-3649, RFC-2988, RFC-6298.

- Jaco88: Van Jacobson, “Congestion Avoidance and Control”, ACM SIGCOMM ’88.
- CJ89: Chiu, D. and R. Jain, .Analysis of the Increase/Decrease Algorithms for Congestion Avoidance in Computer Networks”, Journal of Computer Networks and ISDN Systems, vol. 17, no. 1, pp. 1-14, June 1989.
- Jaco90: Van Jacobson, “Modified TCP Congestion Avoidance Algorithm”, email to end2end-interest@ISI.EDU, April 1990.
- FF96: Fall, K. and S. Floyd, ”Simulation-based Comparisons of Tahoe, Reno and SACK TCP”, Computer Communication Review, July 1996. ftp://ftp.ee.lbl.gov/papers/sacks.ps.Z.
- Wikipedia http://www.wikipedia.org.
- Slides de la Prof. Paula Venosa.
- Slides del Prof. Luis Marrone del curso Ing. de Tráfico.

- TCP/IP Guide: http://www.tcpipguide.com/.
- Transport Layer: http://people.westminstercollege.edu/faculty/ggagne/spring2007/352/notes/unit4/index.html
- Internet ...